

技 术 文 件

版 本： V1.0g

拟 制 Bill

实时构建系统

修改记录

文件编号	版本号	拟制人/ 修改人	拟制/修改 日期	更改理由	主要更改内容 (写要点即可)
	V1.0a	Bill	2019/03/22	文档初稿	
注1：每次更改归档文件(指归档到事业部或公司档案室的文件)时，需填写此表。 注2：文件第一次归档时，“更改理由”、“主要更改内容”栏写“无”。					

概述

buleline是一个非常易用，高性能，能够应对海量数据的实时数据处理产品，构建于**Apache Spark**之上。

1.1 为了解决什么问题？

分布式数据处理入门易，精通难
太多**Spark**重复代码，重复逻辑可以抽象和简化
开发、测试、上线周期长
减少学习成本，加快分布式数据处理能力在生产环境落地

1.2 使用场景

- 海量数据**ETL**
- 海量数据聚合
- 多源数据处理

1.3 特性

- 简单易用，灵活配置，无需开发
- 实时流式处理
- 离线多源数据分析
- 高性能
- 海量数据处理能力
- 模块化和插件化，易于扩展
- 支持利用**SQL**做数据处理和聚合
- 支持**Spark 2.x**

1 input

1.2 StreamingKafkaStream

说明:基于spark streaming 接受kafka数据

支持的Kafka版本 >= 0.10.0

Name	Type	Require	Default
topics	String	yes	
consumer.group.id	String	yes	
consumer.bootstrap.servers	String	yes	
consumer.*	String	no	

topics[string]

Kafka topic名称。如果有多个topic，用","分割，例如：“tpc1,tpc2”。

consumer.group.id [string]

Kafka consumer group id，用于区分不同的消费组。

consumer.bootstrap.servers [string]

Kafka集群地址，多个用","隔开

consumer.* [string]

指定参数的方式是在原参数名称上加上前缀"consumer."，如指定
rebalance.max.retries的方式是: consumer.rebalance.max.retries = 100

Examples

```
kafkaStream {  
    topics = "waterdrop"  
    consumer.bootstrap.servers = "localhost:9092"  
    consumer.group.id = "waterdrop_group"  
    consumer.rebalance.max.retries = 100  
}
```

1.3 StructuredKafkaStream

说明:基于Structuredstreamkafka数据

支持的Kafka版本 >= 0.10.0

Name	Type	Require	Default
topics	String	yes	
consumer.bootstrap.servers	String	yes	

topics[string]

Kafka topic名称。如果有多个topic，用","分割，例如：“tpc1,tpc2”。

consumer.bootstrap.servers [string]

Kafka集群地址，多个用","隔开

Examples

```
kafkaStream {
  topics = "waterdrop"
  consumer.bootstrap.servers = "localhost:9092"
}
```

1.3 Hive

说明：从hive中获取数据

name	type	required	default value
<u>pre_sql</u>	string	yes	-

<u>table_name</u>	string	yes	-
--------------------------	--------	-----	---

pre_sql [string]

进行预处理的sql, 如果不需要预处理,可以使用select * from hive_db.hive_table

table_name [string]

经过pre_sql获取到的数据, 注册成临时表的表名

Example

```
hive {
  pre_sql = "select * from mydb.mytb"
  table_name = "myTable"
}
```

Notes

必须保证hive的metastore是在服务状态。启动命令 `hive --service metastore` 服务的默认端口的9083 `cluster`、`client`、`local`模式下必须把hive-site.xml置于提交任务节点的\$HADOOP_CONF目录下,IDE本地调试将其放在resources目录

1.4 Mysql

说明:获取mysql数据

name	type	required	default value
<u>password</u>	string	yes	-
<u>table</u>	string	yes	-
<u>table_name</u>	string	yes	-
<u>url</u>	string	yes	-
<u>user</u>	string	yes	-

password [string]

密码

table [string]

表名

table_name [string]

注册为Spark临时表的表名

url [string]

JDBC连接的URL。参考一个案例：`jdbc:mysql://localhost:3306/info`

user [string]=

用户名

2.filter

2.1: Json

说明：对原始数据集指定字段进行Json解析

name	type	required	default value
<u>source_field</u>	string	no	raw_message
<u>target_field</u>	string	no	__root__
<u>schema_dir</u>	string	no	-
<u>schema_file</u>	string	no	-

source_field [string]

源字段，若不配置默认为raw_message

target_field [string]

目标字段，若不配置默认为__root__，Json解析后的结果将统一放置Dataframe最顶层

schema_dir [string]

样式目录，若不配置默认为\$***/plugins/json/files/schemas/（建议使用）

```
json {  
    source_field = "message"  
    schema_file = "demo.json"  
}
```

Schema

在 Driver Node 的 /opt/waterdrop/plugins/json/files/schemas/demo.json 中放置内容如下：

```
{  
  "name": "demo",  
  "age": 24,  
  "city": "LA"  
}
```

schema_file [string]

样式文件名，若不配置默认为空，即不指定结构，由系统根据数据源输入自行推导。

2.2 Date

说明：对指定字段进行时间格式转换

name	type	required	default value
<u>default_value</u>	string	no	\${now}
<u>locale</u>	string	no	Locale.US
<u>source_field</u>	string	no	__root__
<u>source_time_format</u>	string	no	UNIX_MS
<u>target_field</u>	string	no	datetime

target_time_format	string	no	yyyy/MM/dd HH:mm:ss
time_zone	string	no	-

default_value [string]

如果日期转换失败将会使用当前时间生成指定格式的时间

locale [string]

编码类型

source_field [string]

源字段，若不配置将使用当前时间

source_time_format [string]

源字段时间格式，当前支持UNIX(10位的秒时间戳)、UNIX_MS(13位的毫秒时间戳)以及SimpleDateFormat时间格式。

Symbol	Description
y	Year
M	Month
d	Day of month
H	Hour in day (0-23)
m	Minute in hour
s	Second in minute

target_field [string]

目标字段，若不配置默认为datetime

target_time_format [string]

目标字段时间格式

time_zone [string]

时区

Examples

```
date {  
  source_field = "timestamp"  
  target_field = "date"  
  source_time_format = "UNIX"  
  target_time_format = "yyyy/MM/dd"  
}
```

2.3 Split

说明:根据delimiter分割字符串。

name	type	required	default value
<u>delimiter</u>	string	no	" "(空格)
<u>fields</u>	array	yes	-
<u>source_field</u>	string	no	root
<u>target_field</u>	string	no	raw_message

delimiter [string]

分隔符，根据分隔符对输入字符串进行分隔操作，默认分隔符为一个空格(" ")。

fields [list]

分割后的字段名称列表，按照顺序指定被分割后的各个字符串的字段名称。若 **fields** 长度大于分隔结果长度，则多余字段赋值为空字符。

source_field [string]

被分割前的字符串来源字段，若不配置默认为 **raw_message**

target_field [string]

target_field 可以指定被分割后的多个字段被添加到Event的位置，若不配置默认为 **_root_**，即将所有分割后的字段，添加到Event最顶级。如果指定了特定的字段，则被分割后的字段将被添加到这个字段的下面一级。

Examples

```
split {  
  source_field = "message"  
  delimiter = "&"  
  fields = ["field1", "field2"]  
}
```

2.4 Sql

使用SQL处理数据，支持Spark丰富的UDF函数

请参考：<http://spark.apache.org/docs/latest/api/sql/>

name	type	required	default value
sql	string	yes	-

table_name	string	yes	-
-------------------	--------	-----	---

sql [string]

SQL语句

table_name [string]

表名，可为任意字符串，这也是sql参数中使用的表名

Examples

```
sql {
  sql = "select username, address from user_info",
  table_name = "user_info"
}
```

2.4 watermark

事件时间水印设置值。抛弃超过设置值对数据只允许基于spark structurestream 引擎中

name	type	required	default value
event_time	string	yes	-
delay_thres hold	string	yes	-

event_time [string]

选择作为水印的字段 必须是timemap时间格式。

delay_threshold [string]

水印值 例子: 30 seconds

Examples

```
watermark {  
    event_time = "logTime"  
    delay_threshold = "30 seconds"  
}
```

3.output

3.1KafkaSink

输出数据到Kafka 基于structurestream

Name	Type	Require	Default
topic	String	yes	
checkpointLocation	String	yes	
producer.bootstrap.servers	String	yes	
outputMode	String	no	Append
triggerMode	string	no	
Interval	String	No	

topic[string]

Kafka topic名称

checkpointLocation[string]

设置checkpoint 进行故障恢复

producer.bootstrap.servers[string]

Kafka集群地址, 多个用","隔开

outputMode [string]

追加(append)(默认) 这是默认的模式.在上次触发后,只有新行添加到结果表(result-table)才会触发。这是只支持那些查询,行添加到结果表永远不会改变,因为这种模式保证每一行将只输出一次。例如,只有选择查询,地图,flatMap,过滤,加入等将支持附加模式

完全(complete) 每次触发时都会将整个结果表(result-table)输出.例如聚合结果等

更新(update) 只有结果表在上次被触发后被更新才会触发

不同的查询支持不同的输出模式,具体见下:

查询类型		支持模式	描述
带聚合的查询	聚合带事件时间的水印	Append, Update, Complete	Append 使用水印来删除旧的聚集状态 窗口将在水印最终阈值的时候聚合.所以结果将在水印过期,最终结果确定的情况下添加进结果表 Update 使用水印来删除旧的聚集状态 Complete 不会使用水印来删除旧的聚集状态
	不带水印的聚合	Complete, Update	由于没有使用水印,旧的聚集状态不会被删除.不支持append,因为对整数据的聚合结果会不断更新,不符合append的语义
mapGroups WithState		Update	

flatMapGroupsWithState	追加操作模式	Append	flatMapGroupsWithState 之后允许 Aggregations （聚合）
	更新操作模式	Update	flatMapGroupsWithState 之后不允许 Aggregations （聚合）。
带join的查询		Append	join不支持Update,Complete模式
其它查询		Append, Update	不支持Complete.因为非聚合数据的结果表,全部保存进结果表时不允许的

triggerMode[string]

触发器

如果不设置任何触发器,将默认使用此触发器.触发规则是:上一个微批处理结束,启动下一个微批处理

建议不使用

Examples

```
kafka {
  producer.bootstrap.servers="172.18.50.66:9091"
  topic="test"
  checkpointLocation="/staructstreaming"
  outputMode = "Append"#Append,Update,Complete
  # triggerMode = "ProcessingTime"
  # interval = "5 seconds"
}
```

3.2 StreamingKafkaSink

输出数据到Kafka 基于sparkstreaming

name	type	required	default value
producer.bootstrap.servers	string	yes	-
topic	string	yes	-
producer.*	string	no	-

producer.bootstrap.servers [string]

Kafka Brokers List

topic [string]

Kafka Topic

producer [string]

除了以上必备的kafka producer客户端必须指定的参数外，用户还可以指定多个producer客户端非必须参数

Examples

```
kafka {  
  topic = "waterdrop"  
  producer.bootstrap.servers = "localhost:9092"  
}
```

3.3 StreamingMysqlSink

streaming输出数据到MySQL

name	type	required	default value
password	string	yes	-
save_mode	string	no	append
table	string	yes	-
url	string	yes	-
user	string	yes	-

password [string]

密码

save_mode [string]

存储模式，当前支持overwrite，append，ignore以及error。每个模式具体含义见

<http://spark.apache.org/docs/2.2.0/sql-programming-guide.html#save-modes>

table [string]

表名

url [string]

JDBC连接的URL。参考一个案例：[jdbc:mysql://localhost:3306/info](#)

user [string]

用户名

Example

```
mysql {  
  url = "jdbc:mysql://localhost:3306/info"  
  table = "access"  
  user = "username"
```

```
password = "password"
save_mode = "append"
}
```

3.4 Elasticsearch

输出数据到Elasticsearch，支持的Elasticsearch版本为 $\geq 2.x$ 。

name	type	required	default value
hosts	array	yes	-
index_type	string	no	log
index_time_format	string	no	yyyy.MM.dd
index	string	no	waterdrop
es	string	no	

hosts [array]

Elasticsearch集群地址，格式为host:port，允许指定多个host。如["host1:9200", "host2:9200"]。

index_type [string]

Elasticsearch index type

index_time_format [string]

当index参数中的格式为时xxxx- $\{now\}$ ，index_time_format可以指定index名称的时间格式，默认值为yyyy.MM.dd。常用的时间格式列举如下：

Symbol	Description
y	Year
M	Month
d	Day of month
H	Hour in day (0-23)
m	Minute in hour
s	Second in minute

index [string]

Elasticsearch index名称，如果需要根据时间生成index，可以指定时间变量，如：\${now}。now 代表当前数据处理的时间。

es.* [string]

用户还可以指定多个非必须参数，详细的参数列表见
如es.batch.size.entries指定的方式是:es.batch.size.entries = 100000。如果不指定这些非必须参数，它们将使用官方文档给出的默认值。

Examples

```
elasticsearch {
  hosts = ["localhost:9200"]
  index = "waterdrop"
}
```

将结果写入Elasticsearch集群的名称为waterdrop的index中

```
elasticsearch {
  hosts = ["localhost:9200"]
  index = "name-${now}"
  es.batch.size.entries = 100000
  index_time_format = "yyyy.MM.dd"
}
```

3.5 Hdfs

输出数据到HDFS文件

name	type	required	default value
options	object	no	-
partition_by	array	no	-
path	string	yes	-
path_time_format	string	no	yyyyMMddHHmmss
save_mode	string	no	error
serializer	string	no	json

options [object]

自定义参数

partition_by [array]

根据所选字段对数据进行分区

path [string]

Hadoop集群文件路径，以hdfs://开头

path_time_format [string]

当path参数中的格式为时xxxx-`{now}`，`path_time_format`可以指定HDFS路径的时间格式，默认值为 `yyyy.MM.dd`。常用的时间格式列举如下：

Symbol	Description
y	Year
M	Month
d	Day of month
H	Hour in day (0-23)
m	Minute in hour
s	Second in minute

save_mode [string]

存储模式，当前支持`overwrite`，`append`，`ignore`以及`error`。

serializer [string]

序列化方法，当前支持`csv`、`json`、`parquet`、`orc`和`text`

Example

```
hdfs {  
  path = "hdfs:///var/logs-{now}"  
  serializer = "json"  
  path_time_format = "yyyy.MM.dd"  
}
```

3.6 MysqlSink

structuredstreaming 下输出到mysql

name	type	required	default value
<u>password</u>	string	yes	-
<u>save_mode</u>	string	no	append
<u>table</u>	string	yes	-
<u>url</u>	string	yes	-
<u>user</u>	string	yes	-
<u>checkpoint Location</u>	string	yes	
<u>outputMode</u>	string	no	append
<u>prepareStatement</u>	String	Yes	

password [string]

密码

save_mode [string]

存储模式，当前支持overwrite，append，ignore以及error。每个模式具体含义见

<http://spark.apache.org/docs/2.2.0/sql-programming-guide.html#save-modes>

table [string]

表名

url [string]

JDBC连接的URL。参考一个案例：<jdbc:mysql://localhost:3306/info>

user [string]

用户名

checkpointLocation[string]

设置checkpoint

outputMode[string]

输出模式 详情请看上文

prepareStatement[string]

Example

```
MysqlSink{
  mysqlurl="jdbc:mysql://rm-
uf6lh1cc24p213t4l.mysql.rds.aliyuncs.com:3306/
tuya_puti?useSSL=false"
  outputMode="Append"
  checkpointLocation="/Metric_updata"
  user="smart"
  password="smart.daily_rw_1206"
  prepareStatement="INSERT INTO
puti_meter_data(namespace`, `biz_type`, `currency`,
`user_id`, `data1`, `data2`, `gmt_begin`, `gmt_end`,
`creator`, `modifier`, `gmt_create`, `gmt_modified`,
`env`) VALUES (?, ?, ?, ?, ?, ?, ?, ?, ?, 'bigData',
'bigData', ?, ?, ?)"
}
```

4. 自定义input filter output以及udf

1/首先引入 blueline-apis_2.11-0.1.jar到工程

4.1 自定义input

4.1.1 新建类 继承 blueline-apis中 BaseStaticInput

例子:

```
class mystatisticstable extends BaseStaticInput{  
  var config: Config = ConfigFactory.empty()  
  
  override def getDataset(spark: SparkSession):  
Dataset[Row] = {}  
  
  override def setConfig(config: Config): Unit =  
this.config=config  
  
  override def getConfig(): Config = this.config  
  
  override def checkConfig(): (Boolean, String) = {}  
}
```

Input插件在调用时会先执行**checkConfig**方法核对调用插件时传入的参数是否正确，然后调用**prepare**方法配置参数的缺省值以及初始化类的成员变量，最后调用**getDataset**方法将外部数据源转换为**Dataset[Row]**

4.2 自定义filter

Filter是transform操作，负责对**Dataset[Row]**的数据结构进行操作
新建一个类，并继承blueline-apis提供的父类**BaseFilter**

```
class myfilter extends BaseFilter{  
  var conf: Config = ConfigFactory.empty()  
  override def process(spark: SparkSession, df: Dataset[Row]):  
Dataset[Row] = {
```

```

}

override def setConfig(config: Config): Unit = this.conf=config

override def getConfig(): Config = this.conf

override def checkConfig(): (Boolean, String) = {

}
}

```

Filter插件在调用时会先执行checkConfig方法核对调用插件时传入的参数是否正确，然后调用prepare方法配置参数的缺省值以及初始化类的成员变量，最后调用process方法对 Dataset[Row] 格式数据进行处理。

4.3 自定义output

Output是action操作，负责将Dataset[Row]输出到外部数据源或者打印到终端

```

class myoutput extends BaseOutput{
  var config: Config = ConfigFactory.empty()
  override def process(df: Dataset[Row]): Unit = {
  }

  override def setConfig(config: Config): Unit = {this.config=config}

  override def getConfig(): Config = {this.config}

  override def checkConfig(): (Boolean, String) = {}
}

```

Output插件调用结构与Filter插件相似。在调用时会先执行checkConfig方法核对调用插件时传入的参数是否正确，然后调用prepare方法配置参数的缺省值以及初始化类的成员变量，最后调用process方法将 Dataset[Row] 格式数据输出到外部数据源。

4.4 自定义udf

新建一个类，并继承blueline-apis提供的父类
BaseFilter

```
class myfilter extends BaseFilter{
  var conf: Config = ConfigFactory.empty()
  override def process(spark: SparkSession, df: Dataset[Row]):
Dataset[Row] = {
df
}

  override def setConfig(config: Config): Unit = this.conf=config

  override def getConfig(): Config = this.conf

  override def checkConfig(): (Boolean, String) = {

  }
  override def prepare(spark: SparkSession): Unit = {
spark.udf.register("isAdult", isAdult _)
}
  def isAdult(age: Int) = {
    if (age < 18) {
      false
    } else {
      true
    }
  }

}
}
```

在调用时会先执行checkConfig方法核对调用插件时传入的参数是否正确，然后调用prepare方法配置参数的缺省值以及初始化类的成员变量和udf的注册，最后调用process方法将 Dataset[Row] 格式数据输出到外部数据源。之后便可在sql 内使用udf方法。

4.5 打包

需要将第三方Jar包放到， `plugins/your_plugin_name/lib/your_jar_name` (必须新建lib文件夹)

例子： `plugins/app/lib/app.jar`

5 部署与运行

Waterdrop 依赖Java运行环境和Spark

5.1 部署

解压即可使用

5.2 运行

```
./bin/start-blueline.sh --master local[4] --deploy-mode client  
--engine structuredstreaming --config ./config/Metric3.conf
```

—master 运行模式 目前支持三种 local[4], yarn,mesos

—deploy-mode:client,cluster

—engine:sparkstreaming,structuredstreaming

5.3 sparkstreaming模式 分为batch和streaming 根据input不同 自动进行识别

batch模式：

input	filter	output
Hive	不包括WaterMark	不包括kafkasink和Mysqlsink
Jdbc		
Mysql		

streaming模式

input	filter	output
StreamingKafkaStream	不包括WaterMark	不包括kafkasink和Mysqlsink

5.4 structuredstreaming 模式

input	filter	output
StructuredKafkaStream	都适用	KafkaSink
		MysqlSink

6 任务并行计算 StreamingPipeline

可以设置多个filter 和 output

例子:

```
spark {
  spark.streaming.batchDuration = 5
  spark.app.name = "app_statistics"
  spark.executor.instances = 2
  spark.executor.cores = 1
  spark.executor.memory = "1g"
}
input {
  kafkaStream {
    topics = "app_real_time_log"
    consumer.bootstrap.servers = "172.18.50.66:9091"
    consumer.group.id = "app_statistics_2010305"
    consumer.rebalance.max.retries = 100
  }
}
filter{
  json {
    source_field = "raw_message"
    #target_field = "info"
  }
}
StreamingPipeline <p1> {
  filter {
    sql {
      sql = "select * from app_info group by info",
      table_name = "app_info"
    }
  }
  output {
    stdout {}
  }
}
StreamingPipeline <p2> {
  filter {
    sql {
      sql = "select * from app_info group by info",
      table_name = "app_info"
    }
  }
  output {
    stdout {}
  }
}
```